


Preservação do perfil de cooperação preditiva entre canais de informação

O treinamento com amostras sintéticas preserva o perfil observado com treinamento real?

Paulo Renato Azevedo

Programa de Pós-Graduação em Informática • UFRJ


Ciência de Dados • 2026



subconjuntos de canais
desempenho relativo que
muda com o tamanho amostral

Amostras sintéticas não são usadas para aumentar a acurácia: investigamos se o treinamento sintético reproduz a cooperação observada com o treinamento real.


Por que comparar subconjuntos de canais?



Antes de decidir quais canais manter, remover ou combinar, é necessário compreender como eles cooperam na classificação.

Fonte: Guyon e Elisseeff (2003); Brown et al. (2012); Hughes (1968); Raudys e Jain (1991).

O que é o perfil de cooperação preditiva?



1. Desempenho

para cada subconjunto, um classificador é treinado e avaliado

2. Ranking em cada n

subconjuntos ordenados pela perda média no teste real

3. Evolução com n

o desempenho relativo muda quando n cresce

O perfil de cooperação preditiva descreve como o desempenho relativo dos subconjuntos evolui com o tamanho do treinamento; não é apenas o subconjunto vencedor.

Fonte: elaboração própria; esquema conceitual, sem valores experimentais.

Pergunta científica e escopo

Em que medida o treinamento com amostras sintéticas preserva o perfil de cooperação preditiva observado com treinamento real?


**Não é aumento
de dados.**

**Não é busca de
maior acurácia.**

**É avaliar a preservação
do perfil observado.**

Fonte: estratégia inspirada em Train on Synthetic, Test on Real: Esteban, Hyland e Rätsch (2017).

Três braços, um único teste real



Grade $n = 2, \dots, 512$ por classe


Monte Carlo réplicas até perda média estimada com precisão alvo

Subconjuntos não vazios: 31 ou 127

Fonte: elaboração própria (figura do protocolo experimental, também usada no relatório final).

Métrica 1 – a ordenação global foi preservada?

(a) **Correlação de ranking**
ordenação global



Cada n produz uma ordenação completa por perda média, não só o primeiro colocado

Correlação de Spearman

ordenação sintética vs. referência Real $\rightarrow$ Real


$$\rho_{\text{rank}} \approx 1$$

organização global semelhante nos dois treinamentos

Correlação alta tolera trocas locais; não exige o mesmo primeiro colocado.

Fonte: figura conceitual do relatório final; Spearman (1904).

Métrica 2 – decisões “A vence B”



Para cada par de subconjuntos

vence quem tem menor perda média; empate exato inicial fica indefinido, empate posterior mantém o vencedor anterior

Winner Agreement (A_W)


proporção de pares com o mesmo vencedor efetivo nos braços real e sintético

uma troca no topo $\neq$ colapso do perfil

Quantas relações de superioridade entre alternativas permanecem iguais?

Fonte: definição e figura conceitual do relatório final do ColInfoSim.

Métricas 3 e 4 – quais pares invertem e em que regime amostral?




A_R – **concordância de existência**
os mesmos pares apresentam ao menos uma inversão válida nos dois braços?

S_R – **similaridade amostral**
nos pares compartilhados, as últimas inversões ocorrem em tamanhos amostrais semelhantes?

Existência e tamanho amostral respondem a perguntas diferentes; não há produto entre as métricas.


Occupancy – nenhum gerador vence em todas as métricas



A Gaussiana única termina à frente em ρ_{rank} , A_W e A_R ; o GMM termina à frente em S_R . A conclusão depende da dimensão do perfil e de n .

Fonte: Candanedo e Feldheim (2016); cenário full 000002; séries recalculadas diretamente pelo código atual.


Air Quality + Gaussian NB: ordenação e vencedores quase perfeitos



Ordenação, vencedores, existência e regime amostral das inversões preservados quase integralmente nos dois braços sintéticos — o caso mais forte do estudo.

Fonte: De Vito et al. (2008); cenário full 000005; séries recalculadas diretamente pelo código atual sobre dados brutos regenerados.

SUPPORT2 – desempenho absoluto e perfil são dimensões distintas



Menor perda em $n = 512$: Real 0,4555; Gaussiana única 0,4554; GMM 0,4547; referencial majoritário 0,4687.

Perda absoluta e preservação do perfil respondem a perguntas diferentes; e A_R pode discordar de S_R mesmo para o mesmo par de braços.

Fonte: SUPPORT Principal Investigators (1995); Knaus et al. (1995); cenário full 000008; séries recalculadas diretamente pelo código atual.

Síntese e conclusão

Preservação é multidimensional

ordenação, vencedores, existência e regime amostral das inversões

Geometria, perda e perfil são distintos

nenhum permite inferir os outros

Nenhum gerador foi universalmente superior

o resultado varia entre os cenários avaliados

A preservação do perfil de cooperação preditiva depende da interação entre dataset, classificador, modelo gerador e tamanho amostral. Nenhum indicador isolado resume todas essas dimensões.

O resultado principal não é que amostras sintéticas melhorem o classificador: em determinados cenários, o treinamento sintético preserva o perfil de cooperação preditiva observado com o treinamento real.

Extrapolação e custos permanecem pendentes; A_R/S_R de escala completa já foram recalculados nesta revisão.

Fonte: síntese do relatório final; cenários full 000002, 000005, 000007 e 000008.

Desafios na seleção dos datasets

Disponibilidade pública não implica adequação ao desenho experimental

1. Busca e avaliação

Alvo defensável, canais interpretáveis, volume para Monte Carlo e documentação suficiente.

2. Dois candidatos adiados

CSI Wi-Fi e sistema hidráulico: sessões, janelas e ciclos com dependência temporal exigiriam outra unidade amostral e validação própria.

3. Três cenários selecionados

Occupancy, Air Quality e SUPPORT2: estrutura tabular; preparação, alvo e preditores definidos por cenário.

O desafio foi compatibilizar domínio, unidade amostral e método de avaliação.

Fonte: Relatório final, capítulo 4 e seção 10.6.

Proveniência e integridade experimental

Proveniência = origem + transformação + partição + uso

Origem documentada

Fonte, DOI, arquivo canônico e hash SHA-256 registrados.

Papéis explícitos

Dados reais de treinamento separados do teste real fixo.

Transformações

Alvo, coorte, partição e padronização descritos.

Uso controlado

Geradores e pré-processamento parametrizados apenas no treino.

O teste real informa a avaliação, mas não a parametrização dos geradores nem as decisões de preparação.

O resultado só é interpretável porque o caminho dos dados foi controlado.

Fonte: Relatório final, capítulos 4 e 5; catálogos e relatórios de datasets do ColInfoSim.

Reprodutibilidade computacional

Cada execução registra

- sementes, grade de n , braços, classificadores e subconjuntos;
- padronização, alvo, parâmetros da Gaussiana e componentes do GMM;
- hashes dos arquivos e impressões digitais das partições;
- replicações, parada, execução computacional, versão e IDs.
- resultados que regeneram relatórios e figuras sem repetir o Monte Carlo.

Reprodutibilidade

Executar novamente o mesmo protocolo com os mesmos artefatos e configuração.

Replicabilidade

Obter evidência compatível em novas execuções, implementações ou cenários.

Não basta rodar o experimento: é preciso poder auditar como ele foi rodado.

Fonte: Relatório final, seção 5.8; README e artefatos persistidos em `output/reports`.

Software científico aberto

```
python -m pip install coinfosim
coinfosim --help
coinfosim scenario run occupancy
--mode smoke
```

Software: GPL-3.0-or-later.

Datasets: licenças e requisitos de atribuição tratados separadamente.

- código, documentação e histórico versionados no GitHub;
- pacote coinfosim publicado no PyPI;
- CLI para cenários, datasets, execuções, configuração e publicação;
- relatórios HTML, figuras e resultados persistidos produzidos pelo fluxo;
- regeneração de relatórios e inspeção de execuções pela própria CLI.

O projeto foi organizado como infraestrutura científica reutilizável.

Fonte: README e `pyproject.toml`; GitHub `paulorenatoaz/coinfosim`; PyPI `coinfosim 0.2.1`, verificado em 16 jul. 2026.

SUPPORT2 – uso responsável no experimento

Boas práticas metodológicas

- base pública de pesquisa, com origem e versão documentadas;
- identificador utilizado somente na preparação e auditoria das partições, sendo removido antes do treinamento;
- variáveis de construção do alvo, death e d.time, excluídas dos preditores;
- desfechos alternativos e proxies, hospdead, surv2m e surv6m, também excluídos;
- análise metodológica e agregada, sem finalidade diagnóstica ou recomendação clínica.

Dados médicos públicos continuam exigindo proveniência, controle de vazamento e limites claros de interpretação.

Fonte: SUPPORT2: DOI 10.3886/ICPSR02957.v2; HBiostat; protocolo descrito no capítulo 4 do relatório final.

Definições formais dos quatro indicadores

Correlação de ranking

Postos por perda média estimada nos dois braços:

$$\rho_{\text{rank}}^{(g,f)}(n) = \text{corr}_{\text{Spearman}}(\mathbf{r}^{(R,f)}(n), \mathbf{r}^{(g,f)}(n)).$$

Matriz de vencedores W

Empate exato inicial: indefinido; empate posterior:
mantém o vencedor anterior:

$$W_{ij}(n_k) = \begin{cases} U_{ij}(n_k), & U_{ij}(n_k) \neq 0 \\ W_{ij}(n_{k-1}), & U_{ij}(n_k) = 0, \exists \text{ vencedor anterior} \\ 0, & \text{caso contrário} \end{cases}$$

R (sobrescrito): braço real; g : braço sintético; f : classificador; U_{ij} : resultado par a par observado em n_k .

Fonte: capítulo 6 do relatório final; Spearman (1904).

Winner Agreement (A_W)

$\mathcal{P}_{\text{valid}}$: pares com W definido nos dois braços.

$$A_W^{(g,f)}(n) = \frac{\sum_{(i,j) \in \mathcal{P}_{\text{valid}}} \mathbf{1}\{W_{ij}^{(R,f)}(n) = W_{ij}^{(g,f)}(n)\}}{|\mathcal{P}_{\text{valid}}|}.$$

Matriz de inversões R

Existe se e somente se houve ao menos uma inversão
válida:

$$R_{ij}(n_t) = \max\{n_k \leq n_t : W_{ij}(n_{k-1}) \neq 0, W_{ij}(n_k) \neq 0, W_{ij}(n_k) \neq W_{ij}(n_{k-1})\}$$

Definições formais: concordância de existência e similaridade amostral

Concordância de existência (A_R) e similaridade amostral (S_R) – nunca multiplicadas

$$A_R(n_t) = \frac{|\mathcal{C}_{\text{real}}(n_t) \cap \mathcal{C}_g(n_t)|}{|\mathcal{C}_{\text{real}}(n_t) \cup \mathcal{C}_g(n_t)|}$$

$\mathcal{C}_g(n_t)$: pares com $R^{(g)}$ definido. União vazia:

$A_R = 1$ (ausência em ambos, não posições coincidentes).

$$D_R(n_t) = \text{média}_{\mathcal{C}_{\text{real}} \cap \mathcal{C}_g} |\log_2 R_{ij}^{(g)} - \log_2 R_{ij}^{(\text{real})}|$$

$$S_R(n_t) = \text{clip}_{[0,1]} \left(1 - \frac{D_R(n_t)}{\log_2 n_t - \log_2 n_1} \right)$$

Definida só no suporte compartilhado; sem pares compartilhados: indisponível, nunca 1.

A_R responde se os mesmos pares invertem; S_R , condicional a isso, responde se invertem no mesmo regime amostral. Nunca combinados em produto.

Datasets, partições e espaço de subconjuntos

Dataset	Canais	Subconj.	Dados reais de treino	Teste real fixo	Partição e alvo
Occupancy	5	31	8.143 (6.414/1.729)	12.417 (9.396/3.021)	Partição original; ocupação binária; sem imputação.
Air Quality	5	31	7.192 (5.374/1.818)	1.799 (1.524/275)	Corte cronológico 80/20; $C6H6(GT) \geq 14,5$, percentil 75 calculado apenas no treino.
SUPPORT2	7	127	7.098 (3.768/3.330)	1.775 (943/832)	80/20, semente 0, estratificação conjunta; óbito até 180 dias.

Occupancy

X_1 temperatura; X_2 umidade;
 X_3 luz
 X_4 CO_2 ; X_5 razão de umidade

Air Quality

cinco respostas de sensores
PT08
alvo derivado da referência de
benzeno

SUPPORT2

pressão, frequência
cardíaca/respiratória, temperatura
leucócitos, creatinina e sódio

Fonte: Candanedo e Feldheim (2016); De Vito et al. (2008); SUPPORT Principal Investigators (1995); Knaus et al. (1995).

Configurações dos geradores e classificadores

MODELOS GERADORES POR CLASSE

Gaussiana única

parametrizada a partir dos dados reais de treinamento: média e covariância amostrais no espaço padronizado completo; $\text{ddof}=1$; ridge diagonal apenas se necessário (10^{-10} a 10^{-3}).

GMM

parametrizado a partir dos mesmos dados reais; covariância completa; $K = 1, \dots, 5$; mínimo de 50 observações por componente; menor BIC por classe; $\text{reg_covar}=10^{-6}$, $\text{n_init}=5$.

K escolhido: Occupancy 5/5; Air Quality 5/4; SUPPORT2 5/5.

CLASSIFICADORES

- SVM linear: `SVC(kernel="linear");`
- Regressão Logística: `max_iter=1000;`
- Gaussian Naive Bayes: padrões da versão executada;
- Random Forest no SUPPORT2: 100 árvores, profundidade 12, folha mínima 5, `max_features="sqrt"`.

A configuração do Random Forest foi calibrada somente nos dados reais de treinamento e congelada antes dos três braços.

Resultados adicionais – Occupancy e Air Quality

QUATRO INDICADORES EM $n = 512$, RECALCULADOS DIRETAMENTE PELO CÓDIGO ATUAL

Dataset / classificador	Treinamento → teste	ρ_{rank}	A_W	A_R	S_R
Occupancy	SVM, Gaussiana única → Real	0,9528	0,9204	0,7706	0,7185
	SVM, GMM → Real	0,8774	0,8624	0,7407	0,7552
	Reg. Logística, Gaussiana única → Real	0,9036	0,8839	0,7089	0,7723
	Reg. Logística, GMM → Real	0,8738	0,8903	0,7714	0,8947
	Gaussian NB, Gaussiana única → Real	0,9976	0,9892	0,4364	0,6406
	Gaussian NB, GMM → Real	0,9996	0,9978	0,6667	0,8708
Air Quality	SVM, Gaussiana única → Real	0,8944	0,8882	0,2609	0,8875
	SVM, GMM → Real	0,9580	0,9333	0,4286	0,8500
	Reg. Logística, Gaussiana única → Real	0,9359	0,9118	0,5514	0,8983
	Reg. Logística, GMM → Real	0,9839	0,9613	0,7125	0,9035
	Gaussian NB, Gaussiana única → Real	1,0000	1,0000	0,7816	0,9689
	Gaussian NB, GMM → Real	0,9996	0,9978	0,8836	0,9760


Os quatro indicadores foram recalculados diretamente pelo código atual a partir dos resultados brutos por replicação regenerados nesta revisão (cap. 7). Nenhum valor deriva do antigo N^* .

Fonte: cenários Occupancy 000002, Air Quality 000005; tabelas do capítulo 7 do relatório final.

Curvas cooperativas do Air Quality (Gaussian NB)

UCI Air Quality + Gaussian Naive Bayes: curvas cooperativas

Seleção no braço Real → Real em $n = 512$; todos os painéis usam o mesmo teste real fixo



A organização das curvas é muito semelhante nos três braços: $\{X_2\}$ domina desde amostras pequenas — a base dos valores quase perfeitos de ranking e *Winner Agreement* do slide 10.

Fonte: perdas persistidas das simulações 000015–000017, vinculadas ao cenário Air Quality full 000005.

Resultados adicionais – SUPPORT2

CENÁRIOS FULL 000007 E 000008, $n = 512$

Classificador, treinamento → teste	ρ_{rank}	A_W	A_R	S_R
SVM, Gaussiana única → Real	0,8672	0,8611	0,5262	0,7417
SVM, GMM → Real	0,9708	0,9343	0,6003	0,7921
Reg. Log., Gaussiana única → Real	0,9853	0,9513	0,5157	0,7376
Reg. Log., GMM → Real	0,9827	0,9461	0,4872	0,7549
Gaussian NB, Gaussiana única → Real	0,7915	0,7950	0,5632	0,7343
Gaussian NB, GMM → Real	0,9144	0,8713	0,7849	0,7473
Random Forest, Gaussiana única → Real	0,8387	0,8281	0,5052	0,8165
Random Forest, GMM → Real	0,8665	0,8429	0,4272	0,8059

Todos os valores desta tabela provêm dos cenários *full* 000007 e 000008 ($n \leq 512$); nenhum resultado de execução em escala reduzida é usado como evidência.

Fonte: cenários SUPPORT2 full 000007 e 000008; indicadores recalculados pelo código atual; cap. 7 e apênd. A/B.

Limitações e ameaças à validade

Validade experimental

- um particionamento por dataset;
- parada controla perdas, não diretamente as métricas;
- treinamento balanceado não reproduz toda prevalência operacional;
- somente perda 0-1.

Validade externa

- três datasets binários, tabulares e de baixa dimensão;
- Random Forest apenas no SUPPORT2;
- geradores não modelam deriva, temporalidade, ausência ou coleta;
- custo exponencial em $2^d - 1$.

Limites de interpretação

- Spearman não iguala perdas;
- A_W ignora magnitude; pares indefinidos são ignorados;
- R guarda só a última inversão; A_R ignora direção; S_R só existe no suporte compartilhado;
- sem custos coletados nem extrapolação além da grade.

As figuras geométricas são inspeções exploratórias, não testes formais de ajuste nem provas de preservação do perfil de cooperação preditiva.

Repositório, rastreabilidade e reprodução

Artefatos persistidos

- configurações, sementes, hashes e partições;
- parâmetros de padronização, geradores e classificadores;
- perdas, replicações, motivos de parada e metadados de execução;
- resultados compactados que regeneram relatórios sem repetir Monte Carlo.

Cenários científicos auditados

Occupancy 000002; Air Quality 000005 e full-scale 000006 (grade até 1.024); SUPPORT2 000007; SUPPORT2 + Random Forest 000008.

Fonte: apêndice B do relatório final; Azevedo (2026), repositório ColInfoSim.

REFERÊNCIA CONGELADA Repositório:
`github.com/paulorenatoaz/coinfosim`

Commit científico auditado:
`f7cfb0b3`

(revisão editorial de perfis de cooperação preditiva, branch
`feature/academic-report-revision`)

Índice dos relatórios:
`paulorenatoaz.github.io/coinfosim/`

O commit auditado é a âncora científica. O HEAD e os metadados de versão atuais podem evoluir independentemente.

Bibliografia I



Azevedo, Paulo Renato (2026). *ColInfoSim: A Simulator for Cooperative Classification from Multiple Information Channels*. Software de pesquisa; revisão editorial de perfis de cooperação preditiva, commit f7cfb0b3. URL: <https://github.com/paulorenatoaz/coinfosim>.



Breiman, Leo (2001). "Random Forests". Em: *Machine Learning* 45.1, pp. 5–32. DOI: 10.1023/A:1010933404324.



Brown, Gavin, Adam Pocock, Ming-Jie Zhao e Mikel Luján (2012). "Conditional Likelihood Maximisation: A Unifying Framework for Information Theoretic Feature Selection". Em: *Journal of Machine Learning Research* 13, pp. 27–66. URL: <https://www.jmlr.org/papers/v13/brown12a.html>.



Candanedo, Luis M. e Véronique Feldheim (2016). "Accurate Occupancy Detection of an Office Room from Light, Temperature, Humidity and CO2 Measurements Using Statistical Learning Models". Em: *Energy and Buildings* 112, pp. 28–39.



Cortes, Corinna e Vladimir Vapnik (1995). "Support-Vector Networks". Em: *Machine Learning* 20, pp. 273–297.



De Vito, Saverio, Ettore Massera, Marco Piga, Luca Martinotto e Girolamo Di Francia (2008). "On Field Calibration of an Electronic Nose for Benzene Estimation in an Urban Pollution Monitoring Scenario". Em: *Sensors and Actuators B: Chemical* 129.2, pp. 750–757.

Bibliografia II



Esteban, Cristóbal, Stephanie L. Hyland e Gunnar Rätsch (2017). “Real-valued (Medical) Time Series Generation with Recurrent Conditional GANs”. Em: *arXiv preprint arXiv:1706.02633*. DOI: 10.48550/arXiv.1706.02633.



Guyon, Isabelle e André Elisseeff (2003). “An Introduction to Variable and Feature Selection”. Em: *Journal of Machine Learning Research* 3, pp. 1157–1182.



Hand, David J. e Keming Yu (2001). “Idiot’s Bayes: Not So Stupid After All?” Em: *International Statistical Review* 69.3, pp. 385–398.



Hosmer, David W., Stanley Lemeshow e Rodney X. Sturdivant (2013). *Applied Logistic Regression*. 3ª ed. Hoboken: Wiley.



Hughes, Gordon F. (1968). “On the Mean Accuracy of Statistical Pattern Recognizers”. Em: *IEEE Transactions on Information Theory* 14.1, pp. 55–63. DOI: 10.1109/TIT.1968.1054102.



Inter-university Consortium for Political and Social Research (2006). *Study to Understand Prognoses and Preferences for Outcomes and Risks of Treatments (SUPPORT)*. ICPSR. DOI: 10.3886/ICPSR02957.v2.

Bibliografia III



Knaus, William A., Frank E. Harrell, Joanne Lynn, Lee Goldman, Russell S. Phillips, Alfred F. Connors, Neal V. Dawson, William J. Fulkerson, Robert M. Califf, Norman Desbiens et al. (1995). “The SUPPORT Prognostic Model: Objective Estimates of Survival for Seriously Ill Hospitalized Adults”. Em: *Annals of Internal Medicine* 122.3, pp. 191–203.



McLachlan, Geoffrey J. e David Peel (2000). *Finite Mixture Models*. New York: Wiley.



Pedregosa, Fabian, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg et al. (2011). “Scikit-learn: Machine Learning in Python”. Em: *Journal of Machine Learning Research* 12, pp. 2825–2830. URL: <https://www.jmlr.org/papers/v12/pedregosa11a.html>.



Raudys, Sarunas J. e Anil K. Jain (1991). “Small Sample Size Effects in Statistical Pattern Recognition: Recommendations for Practitioners”. Em: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 13.3, pp. 252–264. DOI: 10.1109/34.75512.



Schwarz, Gideon (1978). “Estimating the Dimension of a Model”. Em: *The Annals of Statistics* 6.2, pp. 461–464. DOI: 10.1214/aos/1176344136.

Bibliografia IV



Spearman, Charles (1904). "The Proof and Measurement of Association between Two Things". Em: *The American Journal of Psychology* 15.1, pp. 72–101. DOI: [10.2307/1412159](https://doi.org/10.2307/1412159).



The SUPPORT Principal Investigators (1995). "A Controlled Trial to Improve Care for Seriously Ill Hospitalized Patients: The Study to Understand Prognoses and Preferences for Outcomes and Risks of Treatments (SUPPORT)". Em: *JAMA* 274.20, pp. 1591–1598.