


Preservação da estrutura de cooperação entre canais de informação

O treinamento com amostras sintéticas reproduz a evolução da cooperação observada com amostras reais?

Paulo Renato Azevedo

Programa de Pós-Graduação em Informática • UFRJ


Ciência de Dados • 2026



subconjuntos de canais
desempenho relativo que
muda com o tamanho amostral

Amostras sintéticas não são usadas para aumentar a acurácia: investigamos se o treinamento sintético reproduz a cooperação observada com o treinamento real.


Por que comparar subconjuntos de canais?



Antes de decidir quais canais manter, remover ou combinar, é necessário compreender como eles cooperam na classificação.

Fonte: Guyon e Elisseeff (2003); Brown et al. (2012); Hughes (1968); Raudys e Jain (1991).

O que é a estrutura de cooperação?



1. Desempenho

para cada subconjunto, um classificador é treinado e avaliado

2. Ranking em cada n

subconjuntos ordenados pela perda média no teste real

3. Evolução com n

o desempenho relativo muda quando n cresce

A estrutura de cooperação descreve como o desempenho relativo dos subconjuntos de canais evolui à medida que o tamanho do conjunto de treinamento aumenta.

Fonte: elaboração própria; esquema conceitual, sem valores experimentais.

Pergunta científica e escopo

Em que medida a estrutura de cooperação que emerge do treinamento de classificadores com amostras sintéticas reproduz aquela que emerge do treinamento dos mesmos classificadores com amostras reais?


**Não é aumento
de dados.**

**Não é busca de
maior acurácia.**

**É avaliar a preservação da
estrutura de cooperação.**

Fonte: estratégia inspirada em Train on Synthetic, Test on Real: Esteban, Hyland e Rätsch (2017).

Três braços, um único teste real



Grade $n = 2, \dots, 512$ por classe


Monte Carlo replicações até precisão alvo

Subconjuntos não vazios: 31 ou 127

Fonte: elaboração própria (figura do protocolo experimental, também usada no relatório final).

Métrica 1 – a ordenação global foi preservada?

(a) **Correlação de ranking**
ordenação global



Cada n produz uma ordenação completa por perda média, não só o primeiro colocado

Correlação de Spearman

ordenação sintética vs. referência Real $\rightarrow$ Real

$$\rho_{\text{rank}} \approx 1$$

organização global semelhante nos dois treinamentos

Correlação alta tolera trocas locais; não exige o mesmo primeiro colocado.

Fonte: figura conceitual do relatório final; Spearman (1904).

Métrica 2 – decisões “A vence B”

(b) *Winners Agreement*

decisões par a par

objeto formal:
pares não ordenados

visualização:
matriz quadrada



+	+
	-

$q(q-1)/2$ comparações

	+	+
-		-
-	+	

diagonal: não se aplica

Para cada par de subconjuntos

vence o que obtém menor perda média; empates exatos são excluídos

Winners Agreement


proporção de pares com o mesmo vencedor nos braços real e sintético

uma troca no topo $\neq$ colapso da estrutura

Quantas relações de superioridade entre alternativas permanecem iguais?

Fonte: definição e figura conceitual do relatório final do ColInfoSim.

Métrica 3 – quando a superioridade muda?



1. Existência

os mesmos pares cruzam nos dois braços?

2. Posição

o último cruzamento ocorre em regime semelhante?

Similaridade progressiva de N^*


existência $\times$ posição, em prefixos crescentes

N^* pergunta não só quem vence, mas quando a superioridade muda.


Fonte: elaboração própria; definição no relatório final do ColInfoSim.

Occupancy – parecer realista não basta


RESERVATÓRIO REAL



GAUSSIANA ÚNICA



GMM




Linear SVM, $n = 512$ por classe

Treinamento $\rightarrow$ teste	ρ_{rank}	Winners Agreement	Sim. de N^*
Gaussiana única $\rightarrow$ Real	0,9528	0,9204	0,4479
GMM $\rightarrow$ Real	0,8774	0,8624	0,4949

A distribuição que parece mais realista não é necessariamente aquela cujo treinamento melhor reproduz a estrutura de cooperação.

Fonte: painéis geométricos sem classificador. Candanedo e Feldheim (2016); cenário full 000002; valores auditados.

Air Quality + Gaussian NB: preservação ao longo de n




Séries persistidas do cenário full-scale 000006; grade até $n = 1024$; mesmo teste real fixo.


Ranking e relações de vitória são quase integralmente preservados; N^* permanece mais exigente.

Fonte: Air Quality: De Vito et al. (2008); cenário full-scale 000006; valores auditados.

SUPPORT2 – predição $\neq$ estrutura



Menor perda em $n = 512$: Real 0,4555; Gaussiana única 0,4554; GMM 0,4547. Sempre prever a classe majoritária: 0,4687.



Em $n = 512$: GMM melhor em correlação de ranking (0,8665) e *Winners Agreement* (0,8429); Gaussiana única melhor em N^* (0,6799 contra 0,6340).

Perda absoluta e preservação da estrutura de cooperação respondem a perguntas diferentes.

Fonte: SUPPORT: The SUPPORT Principal Investigators (1995); Knaus et al. (1995); cenário full 000008; valores auditados.

Síntese e conclusão

Preservação é multidimensional

ranking, vitórias e N^* são complementares

Geometria, perda e estrutura são distintas

nenhuma permite inferir as outras

Nenhum gerador foi universalmente superior

o resultado varia entre os cenários avaliados

A preservação da estrutura de cooperação depende da interação entre dataset, classificador, modelo gerador e tamanho amostral.

O resultado principal não é que amostras sintéticas melhorem o classificador: em determinados cenários, o treinamento com amostras sintéticas reproduz a organização cooperativa observada com o treinamento real.

Extrapolação e decisões de custo não foram validadas; permanecem hipóteses para pesquisa futura.

Fonte: síntese do relatório final do ColInfoSim; cenários full 000002, 000008 e full-scale 000006.

Desafios na seleção dos datasets

Disponibilidade pública não implica adequação ao desenho experimental

1. Busca e avaliação

Alvo defensável, canais interpretáveis, volume para Monte Carlo e documentação suficiente.

2. Dois candidatos adiados

CSI Wi-Fi e sistema hidráulico: sessões, janelas e ciclos com dependência temporal exigiriam outra unidade amostral e validação própria.

3. Três cenários selecionados

Occupancy, Air Quality e SUPPORT2: estrutura tabular; preparação, alvo e preditores definidos por cenário.

O desafio foi compatibilizar domínio, unidade amostral e método de avaliação.

Fonte: Relatório final, capítulo 4 e seção 10.6.

Proveniência e integridade experimental

Proveniência = origem + transformação + partição + uso

Origem documentada

Fonte, DOI, arquivo canônico e hash SHA-256 registrados.

Papéis explícitos

Reservatório de treinamento separado do teste real fixo.

Transformações

Alvo, coorte, partição e padronização descritos.

Uso controlado

Geradores e pré-processamento parametrizados apenas no treino.

O teste real informa a avaliação, mas não a parametrização dos geradores nem as decisões de preparação.

O resultado só é interpretável porque o caminho dos dados foi controlado.

Fonte: Relatório final, capítulos 4 e 5; catálogos e relatórios de datasets do ColInfoSim.

Reprodutibilidade computacional

Cada execução registra

- sementes, grade de n , braços, classificadores e subconjuntos;
- padronização, alvo, parâmetros da Gaussiana e componentes do GMM;
- hashes dos arquivos e impressões digitais das partições;
- replicações, parada, execução computacional, versão e IDs.
- resultados que regeneram relatórios e figuras sem repetir o Monte Carlo.

Reprodutibilidade

Executar novamente o mesmo protocolo com os mesmos artefatos e configuração.

Replicabilidade

Obter evidência compatível em novas execuções, implementações ou cenários.

Não basta rodar o experimento: é preciso poder auditar como ele foi rodado.

Fonte: Relatório final, seção 5.8; README e artefatos persistidos em `output/reports`.

Software científico aberto

```
python -m pip install coininfosim
coininfosim --help
coininfosim scenario run occupancy
--mode smoke
```

Software: GPL-3.0-or-later.

Datasets: licenças e requisitos de atribuição tratados separadamente.

- código, documentação e histórico versionados no GitHub;
- pacote `coininfosim` publicado no PyPI;
- CLI para cenários, datasets, execuções, configuração e publicação;
- relatórios HTML, figuras e resultados persistidos produzidos pelo fluxo;
- regeneração de relatórios e inspeção de execuções pela própria CLI.

O projeto foi organizado como infraestrutura científica reutilizável.

Fonte: README e `pyproject.toml`; GitHub `paulorenatoaz/coininfosim`; PyPI `coininfosim 0.2.1`, verificado em 16 jul. 2026.

SUPPORT2 – uso responsável no experimento

Boas práticas metodológicas

- base pública de pesquisa, com origem e versão documentadas;
- identificador utilizado somente na preparação e auditoria das partições, sendo removido antes do treinamento;
- variáveis de construção do alvo, death e d.time, excluídas dos preditores;
- desfechos alternativos e proxies, hospdead, surv2m e surv6m, também excluídos;
- análise metodológica e agregada, sem finalidade diagnóstica ou recomendação clínica.

Dados médicos públicos continuam exigindo proveniência, controle de vazamento e limites claros de interpretação.

Fonte: SUPPORT2: DOI 10.3886/ICPSR02957.v2; HBiostat; protocolo descrito no capítulo 4 do relatório final.

Definições formais das três métricas

Correlação de ranking

Postos por perda média nos dois braços:

$$\rho_{\text{rank}}^{(g,f)}(n) = \text{corr}_{\text{Spearman}}(\mathbf{r}^{(R,f)}(n), \mathbf{r}^{(g,f)}(n)).$$

Winners Agreement

$\mathcal{P}_{\text{valid}}$: pares sem empate em ambos os braços.

$$\text{WA}^{(g,f)}(n) = \frac{\sum_{(i,j) \in \mathcal{P}_{\text{valid}}} \mathbf{1}\{W_{ij}^{(R,f)} = W_{ij}^{(g,f)}\}}{|\mathcal{P}_{\text{valid}}|}.$$

Último cruzamento dirigido e similaridade progressiva

$$N_{ij}^*(n_t) = \max\{n_k \leq n_t : \Delta_{ij}(n_{k-1}) \geq 0, \Delta_{ij}(n_k) < 0\}.$$

O evento é dirigido e atribuído ao ponto observado da grade, sem interpolação; registra-se o último evento do prefixo.

$$J(t) = \frac{|C_R(t) \cap C_g(t)|}{|C_R(t) \cup C_g(t)|}, \quad d(t) = \text{média}_{C_R \cap C_g} |\log_2 N_{ij}^{*,g} - \log_2 N_{ij}^{*,R}|.$$

$$T(t) = \text{clip}_{[0,1]} \left(1 - \frac{d(t)}{\log_2 n_t - \log_2 n_1} \right), \quad \text{NS}(t) = J(t) T(t).$$

C_R, C_g : células dirigidas com cruzamento definido.

R : braço real; g : braço sintético; f : classificador; Δ_{ij} : diferença das perdas médias do par dirigido.

Fonte: capítulo 6 do relatório final; Spearman (1904).

Datasets, partições e espaço de subconjuntos

Dataset	Canais	Subconj.	Reservatório de treino	Teste real fixo	Partição e alvo
Occupancy	5	31	8.143 (6.414/1.729)	12.417 (9.396/3.021)	Partição original; ocupação binária; sem imputação.
Air Quality	5	31	7.192 (5.374/1.818)	1.799 (1.524/275)	Corte cronológico 80/20; $C6H6(GT) \geq 14,5$, percentil 75 calculado apenas no treino.
SUPPORT2	7	127	7.098 (3.768/3.330)	1.775 (943/832)	80/20, semente 0, estratificação conjunta; óbito até 180 dias.

Occupancy

X_1 temperatura; X_2 umidade;
 X_3 luz
 X_4 CO_2 ; X_5 razão de umidade

Air Quality

cinco respostas de sensores
PT08
alvo derivado da referência de
benzeno

SUPPORT2

pressão, frequência
cardíaca/respiratória, temperatura
leucócitos, creatinina e sódio

Configurações dos geradores e classificadores

MODELOS GERADORES POR CLASSE

Gaussiana única

parametrizada a partir dos dados reais de treinamento: média e covariância amostrais no espaço padronizado completo; $\text{ddof}=1$; ridge diagonal apenas se necessário (10^{-10} a 10^{-3}).

GMM

parametrizado a partir dos mesmos dados reais; covariância completa; $K = 1, \dots, 5$; mínimo de 50 observações por componente; menor BIC por classe; $\text{reg_covar}=10^{-6}$, $\text{n_init}=5$.

K escolhido: Occupancy 5/5; Air Quality 5/4; SUPPORT2 5/5.

CLASSIFICADORES

- SVM linear: `SVC(kernel="linear");`
- Regressão Logística: `max_iter=1000;`
- Gaussian Naive Bayes: padrões da versão executada;
- Random Forest no SUPPORT2: 100 árvores, profundidade 12, folha mínima 5, `max_features="sqrt"`.

A configuração do Random Forest foi calibrada somente no reservatório real e congelada antes dos três braços.

Resultados adicionais – Occupancy e Air Quality

MÉTRICAS ESTRUTURAIS EM $n = 512$

Dataset / classificador	Treinamento → teste	ρ_{rank}	Winners Agreement	Sim. de N^*
Occupancy	SVM, Gaussiana única → Real	0,9528	0,9204	0,4479
	SVM, GMM → Real	0,8774	0,8624	0,4949
	Reg. Logística, Gaussiana única → Real	0,9036	0,8839	0,5302
	Reg. Logística, GMM → Real	0,8738	0,8903	0,6243
	Gaussian NB, Gaussiana única → Real	0,9976	0,9892	0,2452
	Gaussian NB, GMM → Real	0,9996	0,9978	0,5490
Air Quality	SVM, Gaussiana única → Real	0,8944	0,8882	0,2087
	SVM, GMM → Real	0,9580	0,9333	0,2965
	Reg. Logística, Gaussiana única → Real	0,9359	0,9118	0,4646
	Reg. Logística, GMM → Real	0,9839	0,9613	0,6102
	Gaussian NB, Gaussiana única → Real	1,0000	1,0000	0,7294
	Gaussian NB, GMM → Real	0,9996	0,9978	0,8085


Para N^* , o valor em 512 resume os últimos cruzamentos dirigidos no prefixo 2, ..., 512. No full-scale 000006 (grade até 1.024), os valores do Gaussian NB em $n = 512$ coincidem; em $n = 1024$: 1,0000 / 1,0000 / 0,7319 (Gaussiana única) e 1,0000 / 1,0000 / 0,8095 (GMM).

Fonte: relatórios dos cenários Occupancy 000002, Air Quality 000005 e 000006; tabelas do capítulo 7 do relatório final.

Curvas cooperativas do Air Quality (Gaussian NB)

UCI Air Quality + Gaussian Naive Bayes: curvas cooperativas

Seleção no braço Real → Real em $n = 512$; todos os painéis usam o mesmo teste real fixo



A organização das curvas é muito semelhante nos três braços: $\{X_2\}$ domina desde amostras pequenas — a base dos valores quase perfeitos de ranking e *Winners Agreement* do slide 10.

Fonte: perdas persistidas das simulações 000015–000017, vinculadas ao cenário Air Quality full 000005.

Resultados adicionais – SUPPORT2

Classificador, treinamento → teste	ρ_{rank}	WA	Sim. N^*
SVM, Gaussiana única → Real	0,8672	0,8614	0,3076
SVM, GMM → Real	0,9708	0,9344	0,4145
Reg. Log., Gaussiana única → Real	0,9853	0,9514	0,2932
Reg. Log., GMM → Real	0,9827	0,9461	0,3169
Gaussian NB, Gaussiana única → Real	0,7915	0,7951	0,3196
Gaussian NB, GMM → Real	0,9144	0,8715	0,4590
Random Forest, Gaussiana única → Real	0,8387	0,8282	0,6799
Random Forest, GMM → Real	0,8665	0,8429	0,6340

RANDOM FOREST: N^* DENS0

Referência real: 11.948 cruzamentos definidos.

Gaussiana única: 11.637 definidos; 10.521 compartilhados; Jaccard 0,8053; temporal 0,8442.

GMM: 11.531 definidos; 10.200 compartilhados; Jaccard 0,7681; temporal 0,8254.

A concordância não resulta de matrizes quase vazias.

Fonte: cenários SUPPORT2 000007 e 000008; tabelas do capítulo 7 do relatório final.

Limitações e ameaças à validade

Validade experimental

- um particionamento por dataset;
- parada controla perdas, não diretamente as métricas;
- treinamento balanceado não reproduz toda prevalência operacional;
- somente perda 0-1.

Validade externa

- três datasets binários, tabulares e de baixa dimensão;
- Random Forest apenas no SUPPORT2;
- geradores não modelam deriva, temporalidade, ausência ou coleta;
- custo exponencial em $2^d - 1$.

Limites de interpretação

- Spearman não iguala perdas;
- *Winners Agreement* ignora magnitude e empates;
- N^* guarda apenas o último cruzamento;
- sem custos coletados e sem extrapolação validada além da grade.

As figuras geométricas são inspeções exploratórias, não testes formais de ajuste nem provas de preservação da estrutura de cooperação.

Fonte: capítulo 10 do relatório final.

Repositório, rastreabilidade e reprodução

Artefatos persistidos

- configurações, sementes, hashes e partições;
- parâmetros de padronização, geradores e classificadores;
- perdas, replicações, motivos de parada e metadados de execução;
- resultados compactados que regeneram relatórios sem repetir Monte Carlo.

Cenários científicos auditados

Occupancy 000002; Air Quality 000005 e full-scale 000006 (grade até 1.024); SUPPORT2 000007; SUPPORT2 + Random Forest 000008.

Fonte: apêndice B do relatório final; Azevedo (2026), repositório ColnfoSim.

REFERÊNCIA CONGELADA Repositório:

`github.com/paulorenatoaz/coinfosim`

Commit científico auditado:

`ec5b70baf53bbc67714a61bed64c06358111fb90`

Índice dos relatórios:

`paulorenatoaz.github.io/coinfosim/`

O commit auditado é a âncora científica. O HEAD e os metadados de versão atuais podem evoluir independentemente.

Bibliografia I



Azevedo, Paulo Renato (2026). *ColInfoSim: A Simulator for Cooperative Classification from Multiple Information Channels*. Software de pesquisa; commit científico auditado ec5b70baf53bbc67714a61bed64c06358111fb90. URL: <https://github.com/paulorenatoaz/coinfosim>.



Breiman, Leo (2001). "Random Forests". Em: *Machine Learning* 45.1, pp. 5–32. DOI: 10.1023/A:1010933404324.



Brown, Gavin, Adam Pocock, Ming-Jie Zhao e Mikel Luján (2012). "Conditional Likelihood Maximisation: A Unifying Framework for Information Theoretic Feature Selection". Em: *Journal of Machine Learning Research* 13, pp. 27–66. URL: <https://www.jmlr.org/papers/v13/brown12a.html>.



Candanedo, Luis M. e Véronique Feldheim (2016). "Accurate Occupancy Detection of an Office Room from Light, Temperature, Humidity and CO2 Measurements Using Statistical Learning Models". Em: *Energy and Buildings* 112, pp. 28–39.



Cortes, Corinna e Vladimir Vapnik (1995). "Support-Vector Networks". Em: *Machine Learning* 20, pp. 273–297.



De Vito, Saverio, Ettore Massera, Marco Piga, Luca Martinotto e Girolamo Di Francia (2008). "On Field Calibration of an Electronic Nose for Benzene Estimation in an Urban Pollution Monitoring Scenario". Em: *Sensors and Actuators B: Chemical* 129.2, pp. 750–757.

Bibliografia II



Esteban, Cristóbal, Stephanie L. Hyland e Gunnar Rätsch (2017). “Real-valued (Medical) Time Series Generation with Recurrent Conditional GANs”. Em: *arXiv preprint arXiv:1706.02633*. DOI: 10.48550/arXiv.1706.02633.



Guyon, Isabelle e André Elisseeff (2003). “An Introduction to Variable and Feature Selection”. Em: *Journal of Machine Learning Research* 3, pp. 1157–1182.



Hand, David J. e Keming Yu (2001). “Idiot’s Bayes: Not So Stupid After All?” Em: *International Statistical Review* 69.3, pp. 385–398.



Hosmer, David W., Stanley Lemeshow e Rodney X. Sturdivant (2013). *Applied Logistic Regression*. 3ª ed. Hoboken: Wiley.



Hughes, Gordon F. (1968). “On the Mean Accuracy of Statistical Pattern Recognizers”. Em: *IEEE Transactions on Information Theory* 14.1, pp. 55–63. DOI: 10.1109/TIT.1968.1054102.



Inter-university Consortium for Political and Social Research (2006). *Study to Understand Prognoses and Preferences for Outcomes and Risks of Treatments (SUPPORT)*. ICPSR. DOI: 10.3886/ICPSR02957.v2.

Bibliografia III



Knaus, William A., Frank E. Harrell, Joanne Lynn, Lee Goldman, Russell S. Phillips, Alfred F. Connors, Neal V. Dawson, William J. Fulkerson, Robert M. Califf, Norman Desbiens et al. (1995). “The SUPPORT Prognostic Model: Objective Estimates of Survival for Seriously Ill Hospitalized Adults”. Em: *Annals of Internal Medicine* 122.3, pp. 191–203.



McLachlan, Geoffrey J. e David Peel (2000). *Finite Mixture Models*. New York: Wiley.



Pedregosa, Fabian, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg et al. (2011). “Scikit-learn: Machine Learning in Python”. Em: *Journal of Machine Learning Research* 12, pp. 2825–2830. URL: <https://www.jmlr.org/papers/v12/pedregosa11a.html>.



Raudys, Sarunas J. e Anil K. Jain (1991). “Small Sample Size Effects in Statistical Pattern Recognition: Recommendations for Practitioners”. Em: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 13.3, pp. 252–264. DOI: 10.1109/34.75512.



Schwarz, Gideon (1978). “Estimating the Dimension of a Model”. Em: *The Annals of Statistics* 6.2, pp. 461–464. DOI: 10.1214/aos/1176344136.

Bibliografia IV



Spearman, Charles (1904). "The Proof and Measurement of Association between Two Things". Em: *The American Journal of Psychology* 15.1, pp. 72–101. DOI: [10.2307/1412159](https://doi.org/10.2307/1412159).



The SUPPORT Principal Investigators (1995). "A Controlled Trial to Improve Care for Seriously Ill Hospitalized Patients: The Study to Understand Prognoses and Preferences for Outcomes and Risks of Treatments (SUPPORT)". Em: *JAMA* 274.20, pp. 1591–1598.